자기 입력에서 배우기: 스스로 배움을 조절하는 작은 학습자, 아기의 배움에서 빌린 로직, 그리고 봉인 시험

isolesta-hue (독립 연구자)

판 1.0 — 2026-10-23. 영어 원문(`PAPER.md`)의 한국어 번역본. 수치는 원문 그대로이고, 내용이 다르면 영어 원문이 기준이다. AI의 도움으로 썼다("저자와 AI 사용 밝힘" 참조).

요약

아기는 듣고 본 것을 먼저 기억하고, 그 기억만으로 같은 것을 내 보며, 같아질 때까지 스스로 고친다. 이 내부 따라 하기에서는 입력이 곧 정답이다. 우리는 이 생각을 중심에 둔 작은 학습자 Helix Gold를 만들고, 이런 닫힌 시스템이 **배우는 방식 자체**도 나아지게 할 수 있는지 물었다. 학습자는 입력의 요소를 쓰기 전에 한 번 기억하고 그 뒤로는 바꾸지 않는다(입력 = 정답). 그 "몸"은 한 순간에 함께 들어온 것을 바깥 피드백 없이 짝짓는다. 그리고 방법 층은 학습자가 스스로 만든 시험으로 자기 배움을 조절하되, 더 나을 때만 바꾼 것을 남긴다 — 작은 닫힌 자기 개선 고리다. 그 위에 아기가 세상을 이해해 가는 방식에서 빌린 로직을 주었다. 학습자 자신의 세상 — 나를 중심에 둔 5 × 5 좌표 격자와 글자 그림, 모든 사실이 한 순간 안에 들어오는 세상 — 에서 로직마다 그 로직을 끄고 견주어 몫을 쟀다(사전 등록, 각 30시드, 짝 부호 검정 30:0):

- 학습자가 자기 경험에서 읽어 낸 움직임 "책"으로 굴리는 명시적 월드모델 상태는, 한 번도 함께 들은 적 없는 두 움직임을 이어 붙인다(0.04 → 0.90);
- 맥락 책은 방의 뒤집힘을 그 방에서 들은 적 없는 동사에까지 옮긴다(0.02 → 0.92);
- 물건마다 상태를 따라가면 여러 순간 이야기를 따라간다(0.34 → 1.00);
- 다시 읽어 점검하면 몸이 스스로 하는 말이 오른다(0.45 → 1.00).

스스로 나아지는 고리는 미리 정한 완성 기준을 채웠다. 스스로 조절한 학습자가 고정된 학습자보다 생애 끝에 앞서고(+0.050), 그 차이가 생애 동안 벌어졌다(100시드). 그러나 그 효과는 설계한 로직에 비하면 작다. 설계 밖의 규칙 — 새 범주 낱말, 부정 표지, 새 인과 규칙, 새 순서 규칙 — 은 전혀 배우지 못했다.

그다음 우리는 따로 만든 세 학습자와 함께 공유된 봉인 시험을 치렀다. 시험에는 통과선을 미리 정한 기준 열 개와 기준선 열 개가 있고, 정답 열쇠는 모든 답이 들어올 때까지 어느 저장소 밖에 봉인되어 있었다. 형식 변환기를 거친 Helix Gold의 일반 몸은 기준 10개 중 0개를 통과했다. 기준선 열 개를 모두 이긴 묶음은 물리적 받침 판단 하나뿐이었다. 이름 문항은 0.000~0.056으로 우연 수준(0.038)에 머물렀다. 한 형제 학습자는 채점선으로 10개 중 3개를 통과했지만, 전체 판단으로는 셋 중 어느 것도 아직 온전한 통과가 아니다.

Helix Gold가 맞힌 것은 모두 변환된 입력의 한 순간 안에 사실이 있던 곳이었다. 그리고 변환기는 노출 기록 한 줄(문장 하나와 그 문장이 묘사하는 장면)을 서로 다른 순간들로 나누어 놓았다. 사전 등록한 진단에서 기록 한 줄을 다시 한 단위로 이었지만 이름은 우연 근처에 머물렀다(0.026 → 0.073, 유의하지 않음). 따라서 나눔은 이름 실패의 원인이 아니다. 같은 몸이 자기 세상에서는 여러 장면을 가로질러 새 이름을 배운다. 다른 그림 1~3개가 함께 있는 장면에서 배우고 새 장면에서 시험해 한 번 들으면 0.26, 여덟 번 들으면 0.70이다. 시험에서 달랐던 것은 이름을 **묻는 꼴**이다. 시험은 문장 틀("there is ___")로 묻고, 그 틀의 통계는 흔한 낱말 쪽으로 기운다. 사람 이름은 아예 그 틀로 들린 적이 없다. 이 읽기는 이후 두 학습자에서 진단으로 재었다. Helix Gold 자신의 세상에서는 이름과 함께 들은 적 없는 틀 안에서 물을 때 새 이름이 0.284에서 0.111로 떨어졌다(10시드, 10:0). Helix Teal의 시험 생애에서는 한국어 이름을 들은 꼴로 물으면 0.021에서 0.260으로 올랐다(4생애). 우리는 절차와 결과와 진단을, 옮겨지지 않음의 정직한 사례로 보고한다.

1. 들어가며

이 연구는 아기에 대한 관찰에서 시작했다. 아기는 듣고 본 것을 먼저 기억하고, 그 기억으로 같은 것을 내 보며, 출력이 입력과 같아질 때까지 스스로 고친다. 이 내부 따라 하기에서는 입력이 곧 정답이다. 일반 지도학습은 입력마다 따로 정답을 짝지어 주고, 언어 모델은 그럴듯한 다음 말을 내도록 배운다. 어느 쪽도 입력 자체를 먼저 저장하고 그것을 자기 정답으로 다시 만들어 본 뒤에 쓰지는 않는다. 우리는 내부 따라 하기를 중심에 두고 만든 작은 학습자가 어떻게 되는지, 그리고 바깥의 새 가르침 없이 닫힌 채로 *무엇을* 아는지뿐 아니라 *어떻게* 배우는지도 나아지게 해서, 스스로 고친 판이 고정된 판보다 앞서고 그 차이가 계속 벌어지게 할 수 있는지 물었다. 우리는 이 완성 기준을 재기 전에 정했다(§5). 그런데 그 과정에서 큰 이득의 대부분은 다른 곳에서 왔다. 아기의 배움에서 빌려 학습자에게 설계해 넣은 로직, 특히 나를 중심에 둔 좌표 격자 위에 세운 월드모델이었다. 로직마다 그것을 끄고 견주어 몫을 쟀다. 끄고 견주기는 각 로직이 무엇을 하는지 아는 방법이지, 연구의 대상 자체가 아니다.

그래서 이 분야에 더 중요한 둘째 물음이 생겼다. **그런 설계한 로직은, 같은 학습자가 그 로직에 맞춰 만들지 않은 자료를 만날 때도 옮겨 가는가?** 우리 자신의 치우침 없이 답하려고, 서로 다른 세션이 만든 세 학습자가 같은 날 같은 봉인 시험을 치렀다. 시험은 통과선을 미리 정했고, 모든 답이 들어올 때까지 열쇠를 봉인했고, 단순한 기준선과 학습형 기준선을 두었다.

이 논문은 두 물음의 답을 함께 보고한다. 우리가 보태는 것은 다음과 같다.

1. **내부 따라 하기 위에 세운 학습자와, 값을 잰 아기에게서 빌린 로직**(§3~4). 기억 먼저(입력 = 정답), 피드백 없는 연결, 배우는 방식을 고치는 닫힌 고리; 좌표 격자 글자 그림 세상과, 학습자 자신의 직접 경험에서 "책"을 읽어 내는 월드모델 층. 로직마다 어디서 온 생각인지 말하고, 끄고 견주어 몫을 재며(사전 등록), 사람이 설계한 부분이 어디인지 밝힌다.
2. **출발 물음에 대한 답**(§5). 닫힌 고리는 완성 기준을 채우고, 그 차이는 더 어려운 세상에서 더 벌어진다. 그러나 그 효과는 설계한 로직보다 작고, 설계 밖의 규칙은 배우지 못한다(설계 안 대조를 둔 배우는 힘 시험).
3. **작은 학습자들을 견주는 봉인 시험 절차**(§6). 씨앗 말은 당일에 주고, 열쇠는 봉인했다가 나중에 공개하며, 누구나 씨앗 말에서 판을 다시 만들 수 있고, 기준선 열 개가 모두 같은 문항을 풀며, 걸린 시간도 기록한다.
4. **진단이 붙은 정직한 옮겨지지 않음 결과**(§7). 실패마다 변환기부터 읽는다. 부품별 탐침으로 무엇이 답했는지 보인다. 변환기를 바꾼 진단으로 가장 그럴듯한 설명 — 입력의 구조적 경계 — 을 시험하고 기각한다. 남은 읽기 — 문장 틀이 장면을 이긴다 — 는 두 학습자에서 진단으로 잰다(§8).

2. 관련 연구

함께 나옴으로 낱말 배우기. 교차 상황 학습은 여러 장면을 가로질러 낱말과 대상을 짝짓는다(Siskind 1996; Yu & Smith 2007). Pursuit(Stevens 외 2017)와 propose-but-verify(Trueswell 외 2013)는 가설 하나만 들고 가는 대안이며, 둘 다 우리 기준선에 들어 있다. 빠른 대응(Carey & Bartlett 1978)과 모양 편향(Landau, Smith & Jones 1988)이 우리의 이름·범주 시험의 틀이다.

핵심 지식과 기대 위반. 우리의 물리 기준(받침, 단단함, 맞닿음, 대상 영속성)은 아기의 응시 시간 실험을 따른다(Baillargeon 1987; Spelke & Kinzler 2007). 학습자의 장면 가능도가 낮으면 "더 오래 본다"고 읽는다.

월드모델. 학습형 월드모델은 보통 관찰을 예측이나 계획을 위한 잠재 상태로 압축한다(Ha & Schmidhuber 2018). 우리 것은 반대쪽 끝이다. 명시적인 기호 좌표 상태이고, 그 전이 항목은 학습자 자신의 기억에서 바로 읽는다. Lake 외(2017)의 "시동 소프트웨어" 관점에 더 가깝다.

스스로 나아지기. 자기 참조 학습자(Schmidhuber 2003)와 조기 중단을 쓰는 하이퍼파라미터 탐색(Li 외 2018)이 방법 층의 재료다. 우리는 작고, 닫혀 있고, 잴 수 있는 경우를 다룬다.

틀과 낱말. 통사적 부트스트래핑은 문장 틀이 아이에게 빈자리에 어떤 **종류**의 낱말이 오는지 알려 준다고 본다(Gleitman 1990). **어느** 낱말인지는 장면에서 온다. 우리의 주 읽기(§8)는 바로 이 나눔이 깨진 경우다. 한 아이의 눈과 귀로 본 자료에서 낱말과 대상을 잇는 것이 신경망에서 보여졌다(Vong 외 2024). 작은 근거 학습자에게 알맞은 비교 대상이다.

신경망 기준선. 우리의 학습형 기준선 MLP와 TF, 그리고 Helix Teal의 몸은 트랜스포머 계열의 가린 토큰 예측기다(Vaswani 외 2017; Devlin 외 2019). BabyLM 챌린지(Warstadt 외 2023)가 적은 자료로 배우는 발달형 언어 모델에 가장 가까운 비교 눈금이다.

순서의 기억. 시간 맥락 모형에서는 항목이 그 순간의 천천히 변하는 맥락과 함께 저장되므로, 순서는 항목이 아니라 도장에 담긴다(Howard & Kahana 2002). 상보적 학습 체계는 빠른 일화 기억을 천천히 배우는 패턴과 따로 둔다(McClelland, McNaughton & O'Reilly 1995). 우리의 순서 장치(§9)는 이 두 생각을 단순한 꼴로 따른다.

간섭. 파국적 간섭(McCloskey & Cohen 1989)과 안정성–가소성 딜레마(Mermillod, Bugaiska & Bonin 2013)가 우리의 부정적 결과 둘의 틀이다.

평가. 사전 등록(Nosek 외 2018), 봉인한 시험 세트, Wilson 구간(Wilson 1927)이 우리 절차의 바탕이다. 우리는 다시 만들기 점검을 더한다. 공개한 씨앗 말로 판의 모든 파일 해시를 다시 얻는다.

3. 학습자

설계 원칙(이 연구의 첫 설계에서 와서 지금까지 지킨 것).

- *내부 따라 하기, 기억 먼저.* 모든 요소는 쓰이기 전에 한 번 저장되고 자기 코드에서 다시 만들어진다. 입력이 곧 정답이고, 뒤의 어떤 배움도 저장된 코드를 바꾸지 않는다(§3.1).
- *피드백 없는 연결.* 몸은 한 순간에 함께 들어온 것을 짝짓는다(§3.2).
- *피드백 배움은 무작위 값이 아니라 그 기억에서 시작한다.* 답은 몫을 읽을 수 있는 부분들의 합으로 나뉜다.
- *배우는 방식을 고치는 닫힌 고리.* 방법 층은 바꿈을 사본에서 시험하고, 학습자 자신의 시험이 더 낫다고 할 때만 남긴다. 남겨 둔 사본이 되돌릴 곳이다(§3.3).
- *아기는 생각의 출처이지 본뜰 틀이 아니다.* 아기의 장치를 빌리기 전에 아기에게 그것이 왜 있는지, 그 까닭이 기계에도 있는지를 먼저 묻는다. 없으면 기계에 맞게 바꾼다.

3.1 요소 기억

모든 입력 토큰은 원시 특징 벡터를 가진 *요소*다. 모듈 A는 학습 전에 각 요소를 한 번 외운다. 만들 때 고정한 디코더가 있고, 각 요소의 잠재 부호는 그 디코더에 대해 경사 하강으로 찾는다. 저장된 부호는 그 뒤 바뀌지 않는다. "나" 기준점이 부호 공간의 원점에 있다. 시험의 생애당 약 4,000개 요소에 대해서는, 모든 요소를 떠올릴 수 있을 때까지 모듈 A가 되풀이해 외운다. 떠올리기는 0.9998에 이르므로, 아래의 어떤 결과에서도 기억은 병목이 아니다.

3.2 몸

몸은 **순간**에서 배운다. 함께 들어온 토큰들을 주머니로 다룬다. 빈칸 문항에 대한 답은 정확히 나눌 수 있는 부분들의 합이다(나눔 오차 1e-5):

- **버릇**: 표준화한 맥락 닮음 + 순간 안의 함께 나옴 연결표;

- **틀(템플릿)**: 압축이 될 때만 남기는 관계 틀;
- **통째 기억**(*청크*): 드물수록 무게가 큼;
- **곁가지**: 스스로 만든 재조합으로 연습한 부분.

종류 문지기가 물은 종류의 답만 남긴다. 뒤에서 중요한 성질 둘:

- **(i) 몸은 한 순간 안의 요소끼리만 짝짓는다;**
- **(ii) 한 회차의 순간들 사이에는 순서가 없다.**

3.3 방법 층

방법 층은 회차마다 손잡이를 돌린다: 복습 비율, 학습률, 순서와 복습 고르기. 가지치기로 한다. 한 걸음씩 바꾼 가지들을 50 → 100 → 200 에폭 연습시키고, 매번 나은 절반을 남긴다. 가지는 *스스로 만든 잣대*로 고른다. 학습자가 자기 기록에서 지어낸 새 조합 문제이고, 바깥 시험은 절대 쓰지 않는다. 뒤의 판에서는 스스로 *실험*도 한다. 정확한 나눔 덕분에 다시 배우지 않고 "이 부분의 무게가 w배라면?"을 계산한다.

4. 좌표 격자 글자 그림 세상과 아기에게서 빌린 로직

4.1 세상

자리는 *나*(학습자 자신의 자리; 코드에서 그 토큰의 이름은 `na`)를 기준으로 한 5 × 5 격자 위의 토큰 `pos(x, y)`이고, x, y ∈ −2..2이다. 특징이 (x, y)에 선형이어서 한 칸 움직임은 특징 공간의 일정한 차이가 되고, 움직임 동사는 곧 관계 틀이 *된다*. 격자를 일부러 성기게 했다. 모듈 A는 5 × 5의 모든 자리를 알아봤지만 9 × 9 격자에서는 칸의 60~98%만 알아봤다. 그래서 더 고운 격자는 더 고운 기억을 기다린다.

물건은 5 × 5 글자 스프라이트다. 고정된 무작위 "망막"이 스프라이트를 물건의 그림 특징으로 바꾸므로, 비슷한 스프라이트는 가까운 특징을 얻는다.

생애는 여러 방을 지난다. 방마다 새 물건 넷과 두 종류의 순간이 온다:

- **이름 순간**(그림, 이름, 자리);
- **움직임 순간**(그림, 동사, 출발 자리, 도착 자리).

뒤 단계에서 새 동사가 더해지고, 그다음 뒤집힌 방이 나온다. **학습자가 만나는 모든 사실은 한 순간 안에 들어온다.**

4.2 월드모델 층

책. 움직임 낱말마다 움직임 = 기억[도착] − 기억[출발]이다. 학습자 자신의 직접 경험에서, 처음 외운 고정 기억으로 읽는다. 같은 움직임은 횟수와 함께 합치고, 방마다 확인한다.

굴리기. 출발 자리와 움직임 낱말이 둘 이상인 질문에서는, 상태가 출발 자리에서 시작해 책마다의 순수한 움직임(역할 차이를 뺀 것)을 차례로 더한다.

답 부분. 상태가 어느 칸에서 반 칸 안에 들어오면, 그 칸은 쓴 책마다 틀 한 단위만큼의 증거를 받는다. 이것은 따로 된 부분으로 더해지므로 나눔은 정확히 유지된다. 나중에는 확신한 월드모델이 마지막에 말한다 (`+wmlast`): 결정된 굴리기가 그 칸을 다른 부분들 위에 올린다.

같은 꼴의 확장들:

- **맥락 책**(`+wmctx`): 방에서 들은 동사들이 모두 평소 책과 반대로 움직이면 "이 방은 모든 움직임을 뒤집는다"로 읽고, 들은 적 없는 동사도 뒤집는다;

- **물건마다 상태**(`+track`);
- **거꾸로 읽는 책**(묘사용, `+wmrev`);
- **말하기 전 다시 읽기**(`+speak mon`; Levelt 1989의 자기 점검 고리);
- **물건 성질**(`+props`);
- **"막힐 때까지 되풀이"** 낱말(`+grav`);
- **같은 좌표에 놓은 수직선.**

생각이 어디서 왔나. 움직임 낱말의 뜻은 정의로 주지 않고 학습자 자신이 본 일에서 읽는다(책). 공간은 나에서 바깥으로, 나를 원점에 두고 적는다(격자). 물건은 보이지 않을 때도 계속 있고 움직인다(물건마다 상태; 대상 영속성, Baillargeon 1987). 말은 하기 전에 점검한다(다시 읽기; Levelt 1989). 어떤 규칙은 한 곳에서만 통한다(맥락 책). 어느 경우든 아기의 생각은 로직의 *모양*을 주고, 그 안을 채우는 것은 학습자 자신의 기록에서 배운다(아래).

4.3 로직마다의 몫 — 끄고 견주어 잼 (사전 등록, 시드 짝 부호 검정)

로직(발견)	시험	없을 때	있을 때	시드(이김)
월드모델 굴리기(120)	함께 들은 적 없는 두 움직임	0.036	0.902	30 (30:0)
맥락 책(122)	뒤집힌 방의 들은 적 없는 동사	0.022	0.917	30 (30:0)
조사 묶기(123) → 확신한 월드모델이 마지막(125)	한국어 조사 이야기 → 장면	0.072 → 0.407	1.000	30 (각 30:0)
물건마다 상태(126)	여러 순간 이야기, "지금 어디"	0.344	1.000	30 (30:0)
— 같음(126)	대상 영속성 기대 위반	0.378	1.000	30 (30:0)
거꾸로 읽는 책(127)	본 움직임 말하기	0.301 (몸)	1.000	30 (30:0)
말하기 전 다시 읽기(128)	장면 → 한국어 문장 하나	0.45 (몸)	1.00	30 (30:0)
물건 성질(129)	부딪힘	0.500	1.000	30 (30:0)
막힐 때까지 되풀이(130)	바닥까지 / 물건 위로 떨어짐	0.275 / 0.604	1.000 / 1.000	10 (10:0)
같은 좌표의 수직선(136)	들은 적 없는 결과로 더하기; 수직선에서 들은 적 없는 낱말로 빼기	0.000 / 0.035 (몸 / 다른 간격)	1.000 / 1.000	10 (10:0)
세기 부품(155)	물건 → 수 낱말 1~10	0.133 (몸)	1.000	10 (10:0)

무엇을 설계했고 무엇을 배웠나(사람 몫).

- **우리가 설계한 것:** 규칙의 *모양* — 움직임은 차이다; "막힐 때까지 되풀이"; 방이 모든 움직임을 뒤집을 수 있다; 값이 둘인 성질 표.
- **학습자가 자기 기록에서 배운 것:** *어느* 낱말이 어느 움직임인지, 어느 낱말이 되풀이되는지, 어느 조사가 출발을 표시하는지, 어느 방이 뒤집혔는지.

장치마다 설계한 모양이 없으면 거의 쓸모가 없다. 몸 혼자서는 위의 모든 줄에서 우연 근처에 머문다.

설계 부품의 값. 그 세상에 없는 과목의 부품까지 모두 켜면 크게 해친다(발견 159; 3시드, 방향만):

- 한 세상에서 167개 측정 중 48개가 떨어진다;
- 세기가 1.000 → 0.216으로 떨어진다.

부품들은 "여기는 내 세상이 아니다"를 알 길이 없고, 켜지면 언제나 말한다.

5. 닫힌 자기 개선 고리: 물음과 그 답

완성 기준(재기 전에 고정): 같은 자료에서, 스스로 조절하는 방법 층을 가진 학습자가 고정 설정의 같은 학습자를 생애 끝에 이겨야 하고, 그 차이가 회차를 따라 벌어져야 한다(100시드).

- **틀 세상에서 채움**(발견 69): 생애 끝 +0.050(78:21). 차이가 회차마다 벌어진다: +0.009 → +0.011 → +0.015 → +0.029 → +0.034 → +0.043 → +0.050(6~8회차 − 2~4회차: +0.031, 74:26).
- **더 어려운 세상에서 차이가 계속 벌어진다.** 곁가지 낱말의 절반이 모든 주제에 공유되는 세상 사다리에서(발견 111; 100시드) 끝 차이 +0.143(99:1), 후반 벌어짐 +0.033(78:22).
- **스스로 실험은 더 어려운 세상에서 돕는다.** 부분 무게를 스스로 실험으로 고르면 손잡이만 쓸 때보다 끝에서 +0.050 앞선다(발견 115; 25:5, p = 0.0003).

한계.

- 손잡이는 우리가 골랐다.
- 글자 그림 세상에서는 몸이 방법 층에 지렛대를 거의 주지 않는다. 생애 초반에는 바깥 시험도 가지들의 순위를 일관되게 매기지 못한다(신뢰도 0.10~0.22; 발견 100). 그래서 어떤 손잡이를 골라도 결과가 사실상 같다.

배우는 힘 시험(발견 162~165, 173; 사전 등록; 재는 동안 코드 얼림). 어느 부품도 겨냥하지 않은 새 규칙을 세상에 넣고, 설계 안 대조와 견주어 학습 곡선을 쟀다:

과목	종류	끝 정답률	우연	판정
모양 가족마다 새 범주 낱말(162)	설계 밖	0.106	0.25	배우지 못함 — 들을수록 우연 *아래*로 감(0:10)
부정 표지(164)	설계 밖	0.201	≈ 0.25	배우지 못함
미끄러운 바닥이 움직임을 두 배로(165)	설계 밖(새 인과 규칙)	0.128	≈ 0.25	배우지 못함
종이 울린 다음 순간 그 물건이 한 칸 위로(173)	설계 밖(새 순서 규칙; §9의 순서 장치를 단 뇌로 잼)	0.079	0.25	배우지 못함 — 평평, 문항의 약 2/3가 기권
새 동사 둘 잇기(164)	설계 안(책)	첫 들음부터 1.000	—	배움

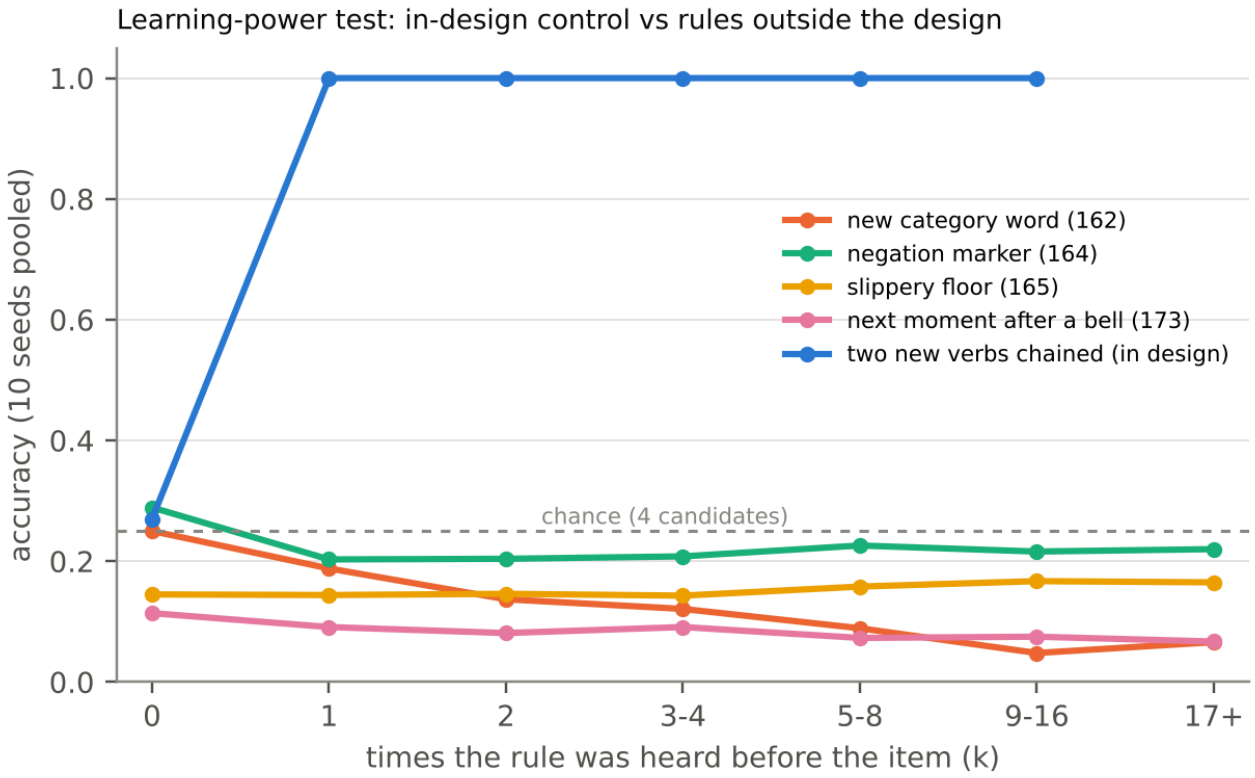


그림 1. 배우는 힘 시험(발견 162~165, 173): 문항 전에 그 규칙을 들은 횟수별 정답률, 10시드를 모음. 설계 안 대조(새 동사 둘 잇기)는 첫 들음부터 1.000; 설계 밖 규칙 넷은 우연이거나 그 아래에 머묾.

설계 의존(설계 안 − 설계 밖, 들은 횟수 1~8)은 +0.79 ~ +0.92(10:0)다. 과목 2와 3은 다른 57개 측정 열쇠 가운데 하나도 움직이지 않았고, 과목 1은 셋을 약 0.05 내렸다. 과목 4는 여섯을 내렸는데, 그 가운데 장면을 움직임 낱말로 말하기(−0.14)가 있다. 규칙의 종 없는 대조 움직임이 생애에 낱말 없는 움직임을 더한 탓으로 보인다. 순서 규칙은 순서 장치가 생기기 전에 고정했다. 장치는 어느 문항에서도 다른 답을 내지 않았다(612개 값 중 0). 장치는 그림이 하나이고 질문 낱말의 뜻을 배운 질문에서만 말하는데, 과목 문항에는 그런 것이 없기 때문이다.

출발 물음의 답. 작은 닫힌 고리는 배우는 방식을 잴 수 있고 벌어지는 차이로 나아지게 *할 수 있다*. 그러나 이 학습자에서 큰 이득은 설계한 로직에서 왔고, 학습자는 아직 새 규칙 *모양*을 배우지 못한다.

6. 봉인 시험 (방법)

6.1 판과 기준

공유 생성기(gen-v1)가 씨앗 하나에서 "생애" 30개를 만든다. 생애마다 세 부분이 있다:

- 16회차의 노출 흐름(생애당 1,752~1,933줄): 한 줄은 한국어 또는 영어 비슷한 언어의 문장 하나와, 그 문장이 묘사하는 5 × 5 격자 위의 장면이다;
- 616~632개 문항, 각자의 회차 뒤에 답함(생애당 답 줄 8,656~8,912);
- 열쇠 파일.

기준 열 개의 통과선은 세 세션이 정하고, 어떤 판도 생기기 전에 사용자가 승인했다:

	기준	통과선(Wilson 95% 아래 끝)
C0	요소 기억(이름, 조사)	≥ 0.99

	기준	통과선**(Wilson 95% 아래 끝)**
C1	새 조합: 누가, 무엇, 어디	각 ≥ 0.85
C2	한 번 들은 낱말("어느 것", 직후)	≥ 0.60; 끝에 남은 정도 ≥ 직후의 0.80
C3	장면 → 수, 수 → 장면(1~10)	≥ 0.90; 어떤 수도 0.70 아래 없음
C4	넣고 뺀 뒤 가르치지 않은 "몇 개"; 빈 상자 짝	≥ 0.80; ≥ 0.85(C3를 통과할 때만 판정)
C5	언어마다 C1; 언어를 건너는 질문	언어마다 C1 선; ≥ 0.70
C6	받침, 단단함, 맞닿음, 영속성(예측과 짝)	각 ≥ 0.90
C7	이야기의 누가, 무엇, 어디(v1에서 "언제"는 보고만)	각 ≥ 0.85
C8	지금 어디 / 직전 어디(보통·긴 이야기)	≥ 0.85; 긴 것 ≥ 0.80
C9	공간 말	≥ 0.90

판의 깊이 하나는 채점 뒤에야 드러났다(Helix Blue의 나중 확인). 받침 문항의 절반(720개 중 360개)은 두 물건이 함께 떨어지는데, 이런 깊이는 노출에 한 번도 나오지 않는다. 노출에서 받침이 빠진 순간 674번은 모두 한 물건만 떨어진다.

기준은 그 선들을 모두 넘어야 통과한다. 전체 판단은 두 가지를 더 묻는다:

- **(b)** 기준선마다 생애별 짝 부호 검정, $p < 0.005$;
- **(c)** 답을 섞은 대조에서 무너질 것.

6.2 절차

1. 생성기, 채점기, 통과선, 기준선 실행기는 여는 날 전에 해시로 고정했다. 각 세션도 여는 날 전에, 답할 몸·변환기·실행기를 지문과 함께 적어 두었다.
2. 여는 날(2026-10-19, 03:00 UTC) 사용자가 씨앗 말을 주었다. 판을 만들어 열쇠 없이 공개했고, 열쇠는 어느 저장소 밖에 봉인했다.
3. 학습자마다 자기 세션이 자기 실행기를 30생애 모두에 돌리고 답 파일을 공개했다.
4. 마지막 답이 들어오자(2026-10-21, 00:03:46 UTC) 열쇠와 씨앗 말을 공개했다. **누구나 씨앗 말에서 판을 다시 만들어 manifest의 파일 해시 90개를 모두 얻을 수 있다.** 모든 답은 공유 채점기로 그대로 채점했다.

6.3 기준선

모든 기준선은 같은 문항을 "답 없음 = 틀림" 규칙 아래 푼다.

단순 기준선 여섯:

- **M** 다수 답;
- **C** 기록 안 함께 나옴;
- **N** 정규화한 함께 나옴;
- **B** 바이그램;
- **L** 낱말 겹침("언제");
- **T** 장면에서 장면으로의 전이 표.

학습형 기준선 넷:

- **P** Pursuit;
- **V** propose-but-verify;
- **MLP**와 **TF**(같은 노출에서 가린 토큰 맞히기). TF는 Helix Teal의 예전 주머니 입력 몸(n0: 2층, 폭 32, 머리 4, 위치 없음)의 꼴이고 처음부터 배운다 — Helix Teal이 시험을 본 흐름 몸이 아니다.

6.4 세 학습자

- **Helix Gold**(이 논문):
  - 자기 몸(§3.2)에 요소 되풀이 외우기를 더해, 변환기 `conv-v1`을 거쳤다.
  - 설계한 월드모델 부품은 붙이지 않았다. 그 부품들은 Helix Gold 자신의 입력 꼴(출발/도착 역할 표지, 동사와 조사 요소)을 읽는데, 충실한 변환기는 그런 꼴을 만들지 않는다. 방법 층도 돌리지 않았다.
  - "언제" 문항(문장 번호)은 지원하지 않아 틀린 것으로 셌다.
- **Helix Teal**: 흐름 트랜스포머 몸(`s1+win2`: 두 단위 창, 나 토큰, 위치)에 경험 기억 섞기를 더해 `ara-conv v1`을 거쳤다(지문 1577ace667de; 실행기 131385ea7675; 몸 시드 = 생애 번호). 두 벌의 답은 같은 생애에서 나왔다: "whole"(트랜스포머 + 기억 섞기)과 "alone"(섞기를 끈 것). "언제"와 "직전 어디"는 여는 날 전에 지원하지 않는다고 밝혔다.
- **Helix Blue**: 따로 설계한 배움 부품들로 된 몸이다. 순간들을 가로지른 함께 나옴으로 낱말과 그림을 짝짓는 듣는 이(이웃 낱말의 순서 기억, 상호 배타성, 세는 감각, 관계 감각과 함께), 두 장면의 차이에서 사건을 읽는 눈, 물건마다 다음 자리를 예측하는 바이오넷 예측기 둘과 사건 책이 있다. 변환기는 `sia-conv-v3`이다(코드 지문 7d03b3b4d445; 실행기 `exam_day.py`, sha 878e0d99840e). "언제"와 "직전 어디"를 포함해 모든 문항 꼴에 답했다(빠진 답 0). 몸 시드 = 1000 × 1000 + 생애 번호; 생애마다 프로세스 하나; BLAS 스레드 하나.

6.5 시간 (사용자가 기록을 요청함)

실행	벽시계	비고
Helix Gold, 30생애	20시간 6분	CPU 52.6시간; 한 번에 3~4생애; 생애당 99~116분
Helix Blue, 30생애	57.6분	프로세스 4개; 생애당 배움 174초 + 답 254초
Helix Teal, 30생애	44시간 41분(판이 열린 때부터 45시간 3분)	CPU 143시간(연습; 답하기는 회차당 약 19초); 끊김 24번(2시간 한도 20번, 컨테이너 재시작 4번), 회차 저장점에서 이어 감; 도중에 호스트 속도가 1.8~2.0배 바뀜
학습형 기준선	3시간 17분	—
단순 기준선	1분 37초	—
채점(답 14벌, 다시 만들기 점검 포함)	1분 29초	—

빠르다고 좋은 것은 아니다. Helix Blue의 빠름의 큰 몫은 일을 대신 해 주는 구조에서 온다(그 세션의 설명). 같은 Helix Gold 생애가 다른 호스트에서는 1.6배 빨랐다.

7. 결과

7.1 점수표

채점선 통과(전체 표는 부록 A):

답	통과한 기준	통과한 선
Helix Blue	**3 / 10**(C0, C2, C9)	33개 중 16
Helix Teal(whole / alone)	0 / 10	33개 중 4(C2 끝에 남음, C6 받침 짝, 단단함 예측과 짝)
Helix Gold	0 / 10	33개 중 2(C2 끝에 남음 0.949, C6 받침 짝 1.000)
기준선 열 개	0 / 10	—

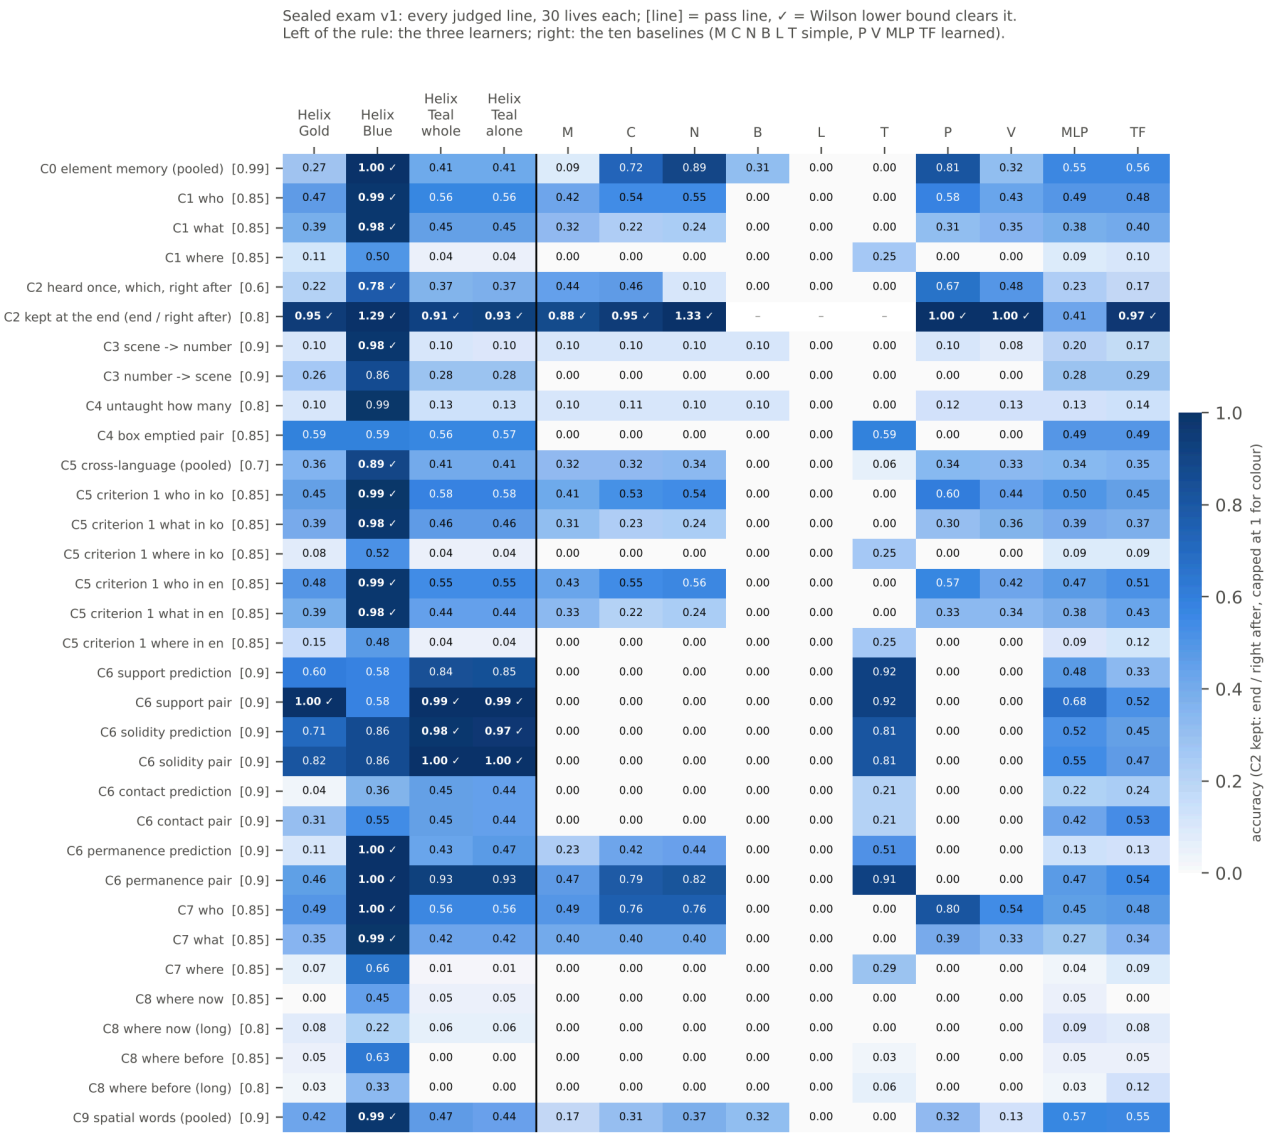


그림 2. 봉인 시험 v1의 판정 줄 전부(각 30생애): 답 묶음마다 정답률, 괄호 안은 통과선, ✓는 95% 윌슨 아래 끝이 선을 넘은 곳(`exam/v1/RESULTS.md`).

Helix Blue의 세 통과를 전체 판단으로 보면:

- **C9**는 30생애 중 27~30생애에서 기준선 열 개를 모두 이긴다($p < 0.0001$).
- **C2**는 기준선 아홉을 이기지만($p < 0.005$) Pursuit 대비로는 미결이다(13승 4패, $p = 0.049$; 규칙상 100생애가 필요).
- **C0**은 관문이라 기준선 규칙 밖이다.
- v1에서는 답을 섞은 대조를 돌리지 않았다.

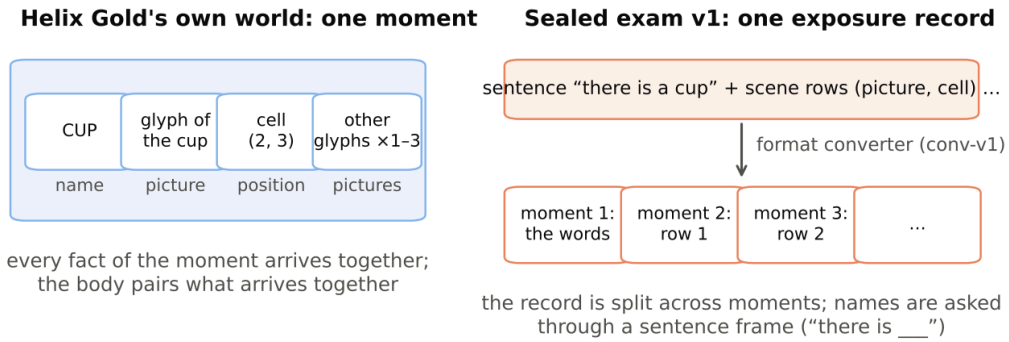
7.2 기준선과 견준 **Helix Gold**

Helix Gold는 딱 한 묶음, C6 받침 짝(1.000)에서 기준선 열 개를 모두 이긴다(생애별 부호 검정, $p < 0.005$). 이름 문항, 새 낱말 곡선, 맞닿음과 영속성, 새 물리 배치, 공간 말 양방향, 이야기 "누가"에서는 적어도 한 기준선에 진다($p < 0.005$). 대부분의 선에서는 가장 나은 단순 기준선 수준에 머문다.

7.3 변환기부터 실패 읽기

Helix Teal 세션이 제안한 순서를 따른다(10-19 형제 읽기, Helix Blue NH 145에서 배움). 먼저 변환기가 문항을 읽었는지 묻고, 그다음 기억, 인출, 로직, 구조 차례로 본다:

1. **지원하지 않은 꼴.** "언제"뿐이다(v1에서는 보고만 하는 선).
2. **변환기가 입력에 한 일.** `conv-v1`은 노출 한 줄을 서로 다른 순간들로 바꾼다. 문장에 순간 하나, 장면 줄(그림 + 자리)마다 순간 하나다. "어느 물건이 어디에 있나"가 주머니 안에서 섞이지 않게 하려는 뜻이었다. **몸은 한 순간 안에서만 짝짓는다.** 그래서 이름과 그 이름이 가리키는 그림은 16회차 동안 한 번도 만나지 못했다. Helix Gold 자신의 세상에서는 이름 순간에 그림, 이름, 자리가 함께 있다(§4.1). 이것이 이름 실패에 대한 우리의 첫 설명이었고, §7.4에서 시험해 기각한다.
3. **증거.**
   - 이름 문항: 사람 0.000(n = 480), 상자 0.008(480), 물건 0.056(960), 우연 0.038.
   - 사람 이름은 두 언어에서 모두 한국어 꼴을 유지한다. 영어 문장 문항 240개 모두에서 Helix Gold는 영어 낱말을 골랐다. 장면이 아니라 문장 언어의 버릇이다.
   - 기록 한 줄(문장 + 장면)을 한 순간으로 세는 기준선 N은 모은 요소 기억 선에서 0.894다.
4. **기억**은 원인이 아니다: 요소 떠올리기 0.9998.
5. **한 순간 안에서는 배움이 된다.** 조사 0.836~1.000(갓난 몸은 0.125~0.333). 받침 짝 1.000(갓난 몸 0.778).



Rejoining a record into one moment did not rescue names (§7.4); asked through a frame, the frame's statistics win over the scene (§8).

그림 3. Helix Gold 자기 세상의 한 순간과, 변환기 `conv-v1`이 몸에 넘긴 봉인 시험의 노출 기록 한 줄.

기준별 관계 표(부록 C). Helix Gold가 우연보다 뚜렷이 높은 묶음은 모두, 변환된 입력의 한 순간 안에 사실이 있다. 순간 사이에 걸친 사실은 관계의 종류와 상관없이 모두 실패한다. 상관(이름, 누가/무엇/어디, 공간 말), 인과나 상호(넣고 빼기, 맞닿음), 선후(영속성, 이야기, 따라가기)가 모두 그렇다. §7.4가 보이듯 그 반대는 성립하지 않는다. 사실을 한 순간 안에 넣는 것만으로는 몸이 배우기에 충분하지 않다.

7.4 진단 생애: 기록 한 줄 = 한 순간

어떤 생애보다 먼저 사전 등록했다(`DIAG_JOINED.md`). `conv-v1j`는 한 가지만 바꾼다. 노출 기록 한 줄이 한 단위가 되어, 문장과 장면 줄을 경계 요소로 잇는다. `conv-v1`이 문항의 맥락을 이미 그렇게 잇는 것과 같다. 생애 001, 007, 018을 시험 자신의 코드와 몸 시드로 다시 돌리고, 기록된 `conv-v1` 답과 채점 규칙으로 견준다.

모은 이름 문항의 판정 규칙:

- **"나눔이 주된 원인"**: ≥ 0.50이고 유의하게 오름;
- **"나눔이 일부 원인"**: 0.50 아래에서 유의하게 오름;
- **"나눔은 원인 아님"**: 둘 다 아님.

끊었다 이어 돈 생애는 끊지 않은 생애를 바이트까지 재현했다. (첫 시도는 메모리가 모자랐다. 단위가 길어지자 몸의 한 단계가 모든 틀의 V × V 행렬을 한꺼번에 들었다. 진단 답을 하나도 채점하기 전에, 값이 비트까지 같고 시험 답도 줄마다 같은 "이어서 최댓값 구하기"로 바꿨다.)

세 생애 모두 점검을 통과했다(기록을 그대로 되살림; 답 줄이 기록된 줄과 같음; 답하는 동안 학습자 그대로). 생애마다 CPU 131~138분이 들었고, 같은 호스트의 `conv-v1` 생애의 약 두 배다.

묶음(3생애 모음)	n	우연	conv-v1(시험)	conv-v1j	바뀐 문항(v1만 / v1j만)	p
이름(사람 + 상자 + 물건)	192	0.038	0.026	0.073	5 / 14	0.064
C1 새 조합 "누가"	72	0.488	0.417	**0.681**	11 / 30	0.004
C7 이야기 "누가"	26	0.500	0.462	0.808	1 / 10	0.012
C9 낱말 → 장면	19	0.333	0.263	0.684	2 / 10	0.039
C6 받침 예측	18	0.333	0.667	**0.000**	12 / 0	0.0005
C6 단단함 예측	18	0.333	0.667	**0.000**	12 / 0	0.0005
C6 받침 짝, 새 배치(보고)	18	0.500	0.167	**0.944**	0 / 14	0.0001
C6 맞닿음 예측, 새 배치(보고)	18	0.333	0.056	**0.833**	0 / 14	0.0001

굵은 글씨는 사전 등록한 유의함이다(문항 단위 양쪽 부호 검정, $p < 0.005$, 차이 절댓값 ≥ 0.02). 전체 표: `diag_joined_v1.md`(Helix Gold 저장소).

- **판정(사전 등록): 이름 실패에 대해 "나눔은 원인 아님".** 문장과 장면을 한 단위에 두어도 이름은 우연 근처에 머문다.
- **답이 그림일 때는 잇기가 돕는다.** "누가"(사람의 그림 고르기)가 오르고, 새 물리 배치 몇 가지도 오른다. **한 물건의 자리 예측은 해친다.** 주머니 안에서는 어느 그림이 어느 칸에 있는지가 섞인다. `conv-v1`이 기록을 나눈 바로 그 까닭이다.
- **읽기(나중에 Helix Gold 자신의 세상에서 진단으로 잼, §8):**
  - 여러 장면을 가로질러 낱말과 그림을 짝짓는 능력이 없어서가 아니다. Helix Gold는 자기 세상에서 다른 그림 1~3개가 함께 있는 순간들로 새 이름을 배우고, 새 장면에서 그 이름을 댄다(발견 149, 10시드: 한 번 들으면 0.26 → 여덟 번이면 0.70, 단순 기준선보다 높음 10:0). 이 논문의 앞 초안은 반대로 적었고, 그것은 틀렸다(`paper1/CHANGES.md`).
  - 다른 것은 질문이다. Helix Gold 자신의 이름 시험은 틀 없는 순간(그림, 자리, 배경 그림)이다. 시험은 문장 틀("there is ‘, ’ 있다") 안에서 묻고, 그 틀의 통계는 흔한 낱말 쪽으로 기울며, 틀 낱말들이 장면을 이긴다. 기록을 이었을 때 낱말에 맞는 그림 고르기("누가")는 올랐지만, 틀 안에 낱말 채우기는 오르지 않았다.
  - 사람 이름의 틀은 사람과 함께 들린 적이 아예 없다(§7.6).

7.5 무엇이 답했나: 부품별 탐침

세 생애를 다시 돌려, 판정 회차의 모든 답을 부분별로 정확히 나누었다(모든 줄이 시험 답과 같음). 답할 때 부분을 하나씩 빼거나 하나만 남겼고, 갓난 몸에도 물었다:

- **판정 묶음 가운데 "구조만으로 되는 것"은 없다**(갓난 몸 ≥ 0.80인 것 없음). Helix Gold가 맞힌 곳은 배운 것이다.
- **조사**는 통째 기억(방향, 목적)이나 버릇(주어)에 기댄다.
- **받침과 단단함**은 버릇에 기댄다.
- **버릇의 닮음 부분은 맞닿음 예측을 해친다.** 빼면 0.056에서 0.722로 오른다($n = 18$, 부호 검정 $p < 0.005$).
- **노출에 없던 물리 배치에서는 배울수록 나빠졌다**: 받침 짝 갓난 0.944 → 0.167, 받침 예측 0.556 → 0.000. 배운 자리 버릇이 본 적 없는 배치를 밀어낸다.

- **이름:** 어느 부분 하나로도 우연에 이르지 못하고, 갓난 몸은 0.000이다.

7.6 형제 학습자들, 그 세션들 자신의 읽기로

각 세션은 이 초안 전에 자기 결과를 읽었다. 우리는 그 읽기를 요약하고 옮겼다(한국어 원문은 부록 E).

Helix Blue(그 `STAGE1_REPLY.md`, 커밋 a078f457; 부품 빼기 탐침 NH 146, 커밋 e7cce8c4):

- C0, C2, C9를 통과했다. 전체 판단으로는 C2가 Pursuit 대비 미결이고 C0은 관문이라, 세션 스스로도 셋 중 어느 것도 아직 온전한 통과라 부르지 않는다.
- v1 생애에서 한 부품 빼기 탐침(답이 줄마다 재현됨)에서, **세 통과는 각각 덧붙인 부품 하나에 기댄다**: C0은 순서 기억(+0.197), C2는 상호 배타성(+0.311), C9는 관계 감각(+0.595). 부품을 모두 빼거나 경험이 없으면 통과는 하나도 없다 — "배운 낱말과 설계한 부품이 함께 푼다".
- 실패에 대한 그 세션의 진단:
  - 상자에서 물건 꺼내기: "어디" 0.004. 상자 안에 같은 모양 물건이 여럿이면 몸이 엉뚱한 것을 가리킨다;
  - 받침과 맞닿음: 다른 물건을 거쳐 전해지는 영향을 놓친다. 그 세션의 나중 확인에서 받침 문항이 노출보다 깊다는 것이 드러났다. 30생애 노출 모두에서 받침이 빠진 순간 674번은 한 물건만 떨어지지만, 받침 문항 720개 중 360개는 두 물건이 함께 떨어진다. Helix Blue는 두 갈래 모두에서 약했다(한 물건: 예측 0.583, 짝 0.583; 두 물건: 0.489, 0.528);
  - 네 관계로 보면: 상관 강함, 인과 대부분 강함, 상호 약함, 선후 약함.
- 빈 상자 짝(0.593)은 "가능도 규칙(설계)의 버릇"이다. 불가능한 보기에 물건이 하나 더 많을 때만 맞힌다.

Helix Teal(`pioneer/README.md` P55, 커밋 d500ca89; 진단 P56, 커밋 80b58629):

- 문법(조사 0.99~1.00)과 물리 예측(받침, 단단함)은 배웠다. whole과 alone이 같다: 경험 기억 섞기는 이 시험에서 아무것도 바꾸지 않는다.
- "장면 속 대상에 낱말을 잇는 것이 우연 근처"라는 첫 읽기는, 시험 코드 그대로 다시 돌린 v1 생애 넷에 대한 사전 등록 진단으로 바로잡혔다(답이 줄마다 같음). 장면을 빼면 물건 이름이 0.289에서 0.047로 떨어진다. 그러니 몸은 장면을 보고 이름을 고른다. 다만 들은 틀 안에서만 그렇다.
- 30생애 전체에서, 물건과 함께 들은 영어 틀("there is ***")로 묻는 물건 이름은 0.631이다. 같은 이름을 조사 없는 한국어 틀(*** 있다", 들은 적 없음)로 물으면 0.108이다. 들은 꼴("<이름> 이/가 있다")로 물으면 한국어 이름 문항이 0.021에서 0.260으로 오른다(4생애). 어느 틀로도 들은 적 없는 사람 이름은 0.000이다.
- **"어디"는 우연과 같다.** 읽기 규칙이 몸이 한 번도 답으로 낸 적 없는 칸 토큰을 물었기 때문이다. 장면 단위로 읽으면(대상의 줄과 후보 칸마다) 0.111로 오른다(우연 0.040). 그 세션의 교훈: 정답을 아는 가짜 몸으로 하는 형식 점검은 꼴만 볼 뿐, 몸이 그런 종류의 답을 낼 수 있는지는 보지 않는다.
- 다음(진행 중): 연습에서 틀 흩뜨리기. 맞힐 낱말 말고 들은 단위의 다른 낱말 몇 개도 빼서, 틀이 아니라 장면이 답을 정하게 한다.

세 학습자를 견주면.

- **빈 상자 짝**은 Helix Blue, Helix Gold, 기준선 T 모두 0.593이다(Helix Teal: 0.564 / 0.566; 장면 단위 읽기도 가능도라 같은 버릇일 가능성이 크지만, 보기 종류별로 확인하지는 않음). Helix Gold는 모든 탐침 변형에서 같은 값이다(§7.5). 배움이 아니라, 장면 가능도가 물건이 하나 적은 보기를 다루는 방식의 성질이다.
- **받침 문항은 노출의 깊이를 넘어서 묻는다**(절반은 두 물건이 떨어지는데, 노출은 이를 보여 준 적이 없음, §6.1). Helix Gold와 Helix Teal은 받침 짝에서 두 물건 문항을 포함해 1.000과 0.99를 얻었다. Helix Blue는 두 갈래 모두 약했다.

- **사람 이름.** Helix Teal의 관찰을 판 전체에서 확인했다. 30생애 노출에서 "there is" 뒤에 낱말이 12,195번 오지만 사람 이름은 한 번도 오지 않는다. 사람 이름 자체는 26,919번 들린다. 그러니 사람 이름 문항은 사람에게 한 번도 쓰인 적 없는 틀로 묻는다:
    - Helix Blue는 문항이 가리키는 물건(설계한 읽기 틀)에 대해 배운 낱말–그림 짝으로 낱말을 고르고, 문장 틀은 쓰지 않는다. 1.000이다;
    - Helix Teal과 Helix Gold는 0.000이다. Helix Teal은 들은 틀 안에서는 장면을 쓴다 ("there is ___"의 물건 이름 0.631, 장면을 빼면 0.047). 그러니 Helix Teal의 실패는 들은 적 없는 틀 때문이지 장면으로 가는 길이 없어서가 아니다.

Helix Gold에게는 이것이 틀이 장면을 이기는 가장 뚜렷한 경우다(§7.4). Helix Gold의 물건 이름은 들은 틀에서도 낮다(영어 "there is ***" 0.113; 들은 적 없는 한국어 "*** 있다" 0.000). 틀이 낯익어도 그 통계가 가장 흔한 낱말 쪽으로 기울기 때문이다.

이름	들은 틀(영어 물건, "there is ___")	들은 적 없는 틀(사람; 한국어 물건 "___ 있다")	장면을 빼면
Helix Blue	1.000	1.000(사람) / 1.000(한국어 물건)	—
Helix Teal	0.631	0.000 / 0.108	0.289 → 0.047(4생애)
Helix Gold	0.113	0.000 / 0.000	—

7.7 기준 삼아 보기: 자기 세상에서 설계 전체 (봉인 아님)

배움의 결과 곁에, 사람 몫이든 바깥 몫이든 가리지 않고 모든 부품·구조·로직을 동원한 모델 전체의 최고 성능을 비교군 하나로 보여 달라는 것이 소유자의 요청이었다. 보여 줄 수 있는 것은 두 가지 사실로 정해진다.

- Helix Gold에게 "모든 부품 켬"은 최고가 아니다. 모두 켜면 측정 167개 중 48개가 떨어지고 세기는 1.000에서 0.216으로 떨어진다(발견 159, §4.3). Helix Gold의 최고 구성은 **세상에 맞는 부품만 켠 것**이다.
- 봉인 시험은 그 구성으로 치르지 않았다(§6.4). 이제 v1의 열쇠는 공개되어 지금 다시 답하면 봉인 시험이 아니다. 게다가 시험 꼴에서는 부품 대부분이 어차피 말하지 못한다.

그래서 **기준으로만** 보인다. Helix Gold의 설계 전체를 자기 세상에서 잰 값을 앞선 사전 등록 결과에서 모으고(개발용 시험; Helix Gold 저장소 `SCORE_TABLE.md`), 봉인 시험에서 몸만으로 낸 답과 나란히 둔다. 자기 세상 쪽은 줄마다 다른 세상이고 그 세상에 맞는 부품을 켰으므로, 그 열은 한 뇌가 아니다.

기준	줄	설계 전체, 자기 세상(개발용, 봉인 아님)	몸만, 봉인 시험 **v1**
C0	요소 기억	0.9993~0.9996(모듈 A 떠올리기)	0.274(시험의 이름·조사 문항)
C1	누가 / 무엇 / 어디	열쇠 없음 / 0.005 / 1.000	0.468 / 0.390 / 0.114
C2	한 번 들은 낱말, 직후; 남은 정도	0.26(한 번) → 0.70(여덟 번); 남음 0.96~1.15	0.217; 남음 0.949
C3	장면 → 수 / 수 → 장면	1.000 / 1.000	0.100 / 0.263
C4	가르치지 않은 "몇 개" / 빈 상자 짝	1.000 / 1.000	0.100 / 0.593
C5	언어를 건너는 질문	0.196	0.357
C6	받침·담김·단단함·영속성(예측 / 기대 위반)	각각 1.000 / 1.000	받침 0.600 / 1.000; 단단함 0.706 / 0.817; 맞닿음 0.039 / 0.306; 영속성 0.106 / 0.456

기준	줄	설계 전체, 자기 세상(개발용, 봉인 아님)	몸만, 봉인 시험 **v1**
C7	누가 / 무엇 / 어디	열쇠 없음 / 0.005 / 1.000	0.491 / 0.348 / 0.065
C8	지금 어디 / 직전 어디	1.000(따라가기) / 1.000(순서 장치, 발견 172)	0.000 / 0.046
C9	공간 말(장면 → 낱말 / 낱말 → 장면)	0.253 / 0.343	0.418(모음)

- 자기 세상에서 설계 전체는 C0·C3·C4에서 시험의 선에 닿고, C6·C8에서는 후보로 닿는다(모든 줄의 아래 끝을 계산하지는 않았다). C2·C5·C9와 C1·C7의 "무엇"에서는 닿지 못한다. 마지막 것은 그 세상의 문항 꼴 문제다(발견 158, 잠정).
- 봉인 시험에서 같은 학습자가 부품 없이 통과한 기준은 하나도 없다.
- 두 열 사이의 거리는 옮겨 가지 못한 설계 구조다. 일부는 부품의 고정된 입력 꼴, 일부는 세상의 모양 때문이다(§8). 두 열은 세상·문항 꼴·뇌가 모두 다르므로, 이 표는 시험이 아니라 기준이다.
- 다음 봉인 판부터 Helix Gold는 같은 날 답을 **두 벌** 낸다. 하나는 배움을 재는 뇌, 하나는 시험 꼴에서 일하는 부품을 모두 켠 설계 전체다. 그래야 이 거리를 봉인 조건에서 잴 수 있다. Helix Teal은 이미 v1에 두 벌(whole과 alone)을 냈다(§6.4).

8. 논의

이득은 왜 옮겨지지 않았나. 설계한 장치들은 v1에서 아예 쓰이지 않았다(§6.4). 그래서 v1은 그 장치들을 재지 않는다. v1이 재는 것은, 일반 몸이 자기에게 맞춰지지 않은 입력에서 무엇을 배우는가이다. 몸은 한 순간 안에 있는 것(조사, 한 물건의 자리)은 배웠고, 순간을 넘는 것은 아무것도 배우지 못했다. 우리의 첫 설명은 순간 경계 그 자체였다. 진단은 이름에 대해 그 설명을 기각했다. 문장과 장면을 이어도 이름은 우연 근처에 머물렀다.

설계한 세상은 사실을 한 순간 안에 두는 것보다 더 많은 일을 했다. 사실을 **배운 꼴 그대로** 물었다:

- 이름은 들은 순간과 같은 틀 없는 순간(그림, 자리, 배경 그림)으로 물었고, Helix Gold는 거기서 여러 장면을 가로질러 이름을 배운다(발견 149);
- 움직임은 출발·도착 표지와 함께 듣고, 같은 꼴로 물었다.

시험은 교과 과정 밖의 언어처럼 문장 틀로 묻는다. 틀은 그 뒤에 어떤 낱말이 오는지에 대한 자기 통계를 지닌다. 모든 증거를 더하는 몸은 틀이 장면을 이기게 둔다. 단순히 더하는 몸이 아닌 Helix Teal의 트랜스포머도 같은 모습을 보였다. **세상은 우리가 알아챈 것보다 더 학습자를 빚었다** — 무엇을 보여 주었는가가 아니라 어떻게 물었는가로. 이 읽기는 이후 두 몸에서 재었다. Helix Gold 자신의 세상에서는 이름과 함께 들린 적 없는 틀 안에서 새 이름이 0.284 → 0.111로 떨어졌다(발견 168, 10:0). 틀 때문에 뒤집힌 답의 81%는 틀과 함께 들린 낱말이었다(흔한 낱말 549 + 틀 낱말 8, 688개 중). 몸은 틀을 배우기는 했다 — 흔한 낱말에는 틀이 도움이 된다(0.715 → 0.843). Helix Teal의 시험 생애에서는 네 생애에 대한 진단으로, 한국어 이름을 들은 꼴로 물으면 0.021 → 0.260으로 오르고, 장면을 빼면 물건 이름이 0.289 → 0.047로 떨어진다. 둘 다 진단이지, 봉인 판에 대한 판정이 아니다. 그래서 우리는 자기 세상 안의 부품 빼기 결과만이 아니라 이것을 주 결과로 보고한다.

사람 몫. 우리 규칙 — 뇌는 전체로 판정하고, 설계한 부품은 이름을 밝힌다 — 을 따르면, §4의 큰 자기 세상 효과는 모두 우리가 쓴 규칙 *모양*을 필요로 했다. 배우는 힘 시험(§5)은 학습자가 아직 새 모양을 얻지 못함을 보인다. 기준 셋을 통과한 형제 학습자는 자기 v1 생애에 대한 부품 빼기 탐침에서, 통과마다 설계한 부품 하나가 배운 낱말–그림 짝과 함께 일한다고 보고한다(순서 기억, 상호 배타성, 관계 감각). 또 빠름의 큰 몫은 설계한 구조에서 온다고 보고한다. 그러니 시험 점수로 학습자를 견주는 것은 설계와 배움을 함께 견주는 것이고, 둘을 가르려면 부품별 탐침이 필요하다.

안정성과 가소성. 배움이 본 적 없는 배치에서 Helix Gold의 답을 낮췄다(§7.5). 새 인과 규칙에서는 아무것도 배우지 못했지만 아무것도 흐트러뜨리지 않았다(발견 165: 다른 열쇠 57개 중 0개가 움직임). 형제 Helix Blue에서는 비슷한 새 인과 규칙(미끄러운 칸)을 예측기가 배웠다(참 읽기를 주면 0.68). 그러나 고정된 설계 부품 — 눈의 닫힌 사건 갈래 목록 — 이 새 효과를 "놓기"로 담았고, 그 꼬리표가 듣는 이가 밀기 문장에 대해 배운 것을 오염시켰다(읽기 0.998 → 0.51). 절대 자리를 보지 않는 사건 책도 새 규칙을 가로막았다(빼면 +0.037)(그 기록 NH 145). 두 몸은 같은 딜레마의 양 끝에 있다.

무엇이 바뀌어야 하나. 이름에 대해서는 Helix Gold의 변환기가 아니다. 변환기를 시험에 맞추는 것은 시험에 맞추는 일이고, 진단은 그래도 충분하지 않음을 보인다. 길이 없는 읽기는 다른 문제다. Helix Teal의 "어디" 읽기는 몸이 한 번도 내지 않은 답을 물었다. Helix Gold의 읽기는 문항의 대상을 버려서, "지금 어디 / 직전 어디" 문항이 어느 물건을 묻는지 말하지 않았다(발견 169). 시험이 모든 학습자에게 주는 것을 넘기도록 읽기를 고치는 일은 시험 맞추기가 아니다. 다만 그 효과는 다음 봉인 판에서 판정해야 한다. 학습자 자신은 세 가지를 해야 한다. (a) 틀은 낱말의 종류만 정하고 어느 낱말이 빈자리를 채울지는 장면이 정하게 하기, (b) 낱말에서 그림뿐 아니라 그림에서 낱말도 꺼내기, (c) 어느 물건이 어디 있는지 잃지 않고 순간을 가로질러 짝짓기. (c)는 배우는 힘 시험에서 미뤄 둔 "순서" 과목과 같은 빈 곳이다.

한계.

- 판 하나, 생애 30개.
- 진단은 생애 셋이고 문항을 모았다.
- 답을 섞은 대조는 돌리지 않았다.
- 세션마다 자기 변환기를 썼다.
- 틀 시험(발견 168)은 Helix Gold 자신의 세상에서, 틀 하나(두 낱말)와 이름의 종류 하나로 재었다. §9의 답할 때 규칙들도 그 세상에서 재었다.
- 준비 점검은 답의 꼴만 보았다(정답을 아는 가짜 몸, 무작위 몸). 읽기가 물은 종류의 답에 이를 수 있는지는 아무도 묻지 않았다. 몸으로 하는 길 점검 — 문항을 노출의 꼴로 가르친 뒤 되묻기 — 은 v1 뒤에 더했다(첫 거름은 공용 `exam/path_check.py`, 몸으로 하는 점검은 세션마다). 개발 판에서 Helix Gold는 35묶음 중 11묶음이 막혀 있었다: 가르쳐도 안 되는 이름들, "지금 어디 / 직전 어디"(읽기가 대상을 넘긴 뒤에도 — 경험에 순서가 없어서), 맞닿음 예측, 빈 상자 짝(발견 169).
- 재현은 세션마다 각자의 조건에서 확인했다(Helix Gold: 모든 BLAS 1스레드; Helix Teal: 프로세스당 torch 1스레드, 같은 종류 호스트에서 다시 돈 생애가 줄마다 같음; Helix Blue: BLAS 1스레드, PYTHONHASHSEED=0). 호스트 종류를 건너 답을 견주지는 않았다.
- Helix Gold는 설계한 부품 없이 시험을 봤다. 시험 전에 밝힌 알려진 빈틈이다. §7.7의 설계 전체 기준은 봉인이 아니다. Helix Gold 자신의 세상들에서, 다른 문항 꼴로, 줄마다 다른 부품 묶음으로 잰 값이다.
- 실행마다 호스트 속도가 달랐다.
- 코드와 글의 대부분은 AI 보조 세션이 만들었다(아래).

9. 맺음과 다음 걸음

내부 따라 하기 위에 세운 작은 닫힌 고리는 배우는 방식을 나아지게 할 수 있다. 그러나 우리 학습자에서 큰 이득은 아기에게서 빌려 설계한 로직에서 왔고, 그 로직의 일부는 세상의 모양에 있었다. 사실이 한 순간 안에 들어왔고, 들은 꼴로 물었다. 열쇠를 공개하고 다시 만들기 점검을 한 봉인 시험이 그 틈을 드러냈고, 사전 등록한 진단이 가장 그럴듯한 설명을 기각했다.

다음 걸음은 일반 배움 장치다. 문장 틀이 아니라 장면이 낱말을 고르게 하고, 순간을 가로질러 짝짓는 장치이며, 먼저 학습자 자신의 세상에서 잰다(틀을 통해 묻는 이름; 미뤄 둔 "순서" 과목).

- (a)에 대한 첫 시도는 실패했다. Helix Gold 자신의 세상에서, 답할 때 "자기 기억이 보이는 그림을 모두 설명하는 낱말"을 고르게 했다. 틀의 영향은 사라졌지만(틀 안 − 틀 없이 −0.173 → −0.002) 옛 낱말 시험이 무너졌고(흔한 낱말 0.715 → 0.066), 사전 등록 판정은 "실패"였다(발견 170).
- (c)와 미뤄 둔 순서 과목에 대해서는 Helix Gold 자신의 세상에 첫 장치가 생겼다.
    - 일화 저장소가 들은 순간을 모두 차례와 함께, 버릇과 따로 둔다.
    - 같은 등호의 생각으로 질문 낱말이 무엇을 묻는지 배운다. 설계한 때 관계 셋(지금, 마지막으로 바뀌기 전, 처음) 가운데 어느 것인지, 그리고 어떤 종류의 답인지다.
    - 본 장면에서 "지금 어디"와 "전에 어디"를 1.000으로 답한다. 버릇만으로는 0.149와 0.208이다(새 시드, 각 10:0; 옛 열쇠는 하나도 움직이지 않음; 발견 171~172).
    - 이 저장소는 본 장면만 때줄에 넣으므로, 시험의 C8처럼 말로만 들은 움직임은 다루지 못했다.
    - 그다음 둘째 저장소가 **말로만 들은 움직임**을 받았다. 장면 부품 — 앞서 문장 앞뒤의 장면에서 표지 없이 움직임 낱말을 배우도록 설계한 부품(발견 160: 섞은 대조가 우연일 때 0.998) — 이 장면 없이 들은 문장을 예상 칸으로 바꾼다 — 그 이름이 전에 움직인 물건을, 서로 다른 물건의 변화와 함께 들린 낱말의 센 움직임만큼 옮긴 칸 — 그리고 바로 뒤에 본 칸이 오면 본 칸이 그 자리를 차지한다. 걷기의 마지막 걸음들을 말로만 들려준 뒤 "지금 어디"와 "전에 어디"가 0.080과 0.102(본 것만의 저장소)에서 1.000으로 올랐다(새 시드, 각 10:0; 본 문항과 옛 열쇠는 그대로; 발견 174). 둘 다 설계 안의 결과다 — 때 관계, 장면 부품의 틀, "들은 것은 예상, 본 것이 이김" 규칙을 우리가 주었다. 시험지 C8은 여전히 다르다: 이야기가 질문 안에 오고, 움직임 대부분이 다른 물건 기준이며, 질문 낱말의 뜻을 배울 가르치는 문답이 없다.
    - 장치가 생기기 전에 규칙을 고정해 둔 순서 과목("종이 울린 다음 순간 그 물건은 한 칸 위로")은 장치를 켜도 배우지 못했다(0.079, 발견 173). 저장소에는 차례가 남지만, 한 순간 뒤에 무엇이 오는지를 읽는 부품이 없다.
- v1은 이미 쓴 판이므로, 세션마다 자기 세상에서만 고침을 고른다. Helix Blue는 진단이 가리킨 두 곳을 고쳤고(NH 147, NH 148), 이어 놓기 열쇠로 자기 세상 따라가기가 처음으로 선 위에 올랐다("지금 어디" 0.900, "직전 어디" 0.890; NH 151). 다음 판에는 `sia-conv-v8`(지문 7cc58971e406)로 답한다. Helix Teal은 연습에서 틀 흩뜨리기 — 낱말이 답일 때 들은 단위의 다른 낱말을 뺌 — 로 들은 적 없는 한국어 꼴의 이름을 0.021에서 0.552로 올렸다(새로 맞힌 이름은 장면에서 옴). 그러나 꼴이 정하는 낱말(조사)이 늦어지고 지킴 줄 넷이 깨져 넓히지 않았다(P57). 다음 후보는 몸이 스스로 잰 "장면이 돕는 정도"가 있는 낱말에만 흩뜨리는 것이다(P58).
- 그다음은 둘째 봉인 판이다. 세 학습자가 다시 같은 날 함께 열고, 견주기에 대한 후속 논문을 쓴다. 그 판에서 Helix Gold는 답을 두 벌 낸다 — 배움을 재는 뇌와 설계 전체(§7.7).

계획 중이거나 보관 중인 연구. 위 걸음 말고도, 프로젝트는 계획했거나 보관했지만 아직 해 보지 않은 생각들을 장부에 두고 있다. 부록 F에 주요한 것을 겨냥하는 빈 곳과 상태(진행 중 / 계획 / 보관 — 보관이면 그 까닭)와 함께 적는다. 어느 것도 결과가 아니다. 큰 줄기는 넷이다.

- 설계와 배움을 봉인 조건에서 갈라 재기: 답 두 벌, 손대지 않은 새 세상, 답 섞기 대조.
- 일반 배움 장치: 장면이 낱말을 고름, 순서와 말로 들은 사건, 다른 물건 기준의 틀, 네 관계, 기호 바꿔 보기 놀이, 한 번 듣고 뜻 잡기.
- 방법 층을 시험 대상으로: 스스로 최적화하기, 문제 해결.
- 5 × 5 글자 그림 세상 너머의 뒤 단계: 그림, 3차원과 시간, 대화.

형제 세션들은 각자 자기 계획을 둔다. 공개한 것은 위에 적었다.

코드와 자료 공개

이 논문과 함께 공개한다(GitHub `isolesta-hue/paper-human-learning-lineages`, Zenodo 보관). 공개하는 것은 다음과 같다.

- `helix_gold/`: Helix Gold의 코드와 기록 — 인용한 모든 결과 파일, 사전 등록과 설계 노트, 번호 붙은 발견이 있는 연구 기록, 장부.
- `exam/`, `exam_spec/`: 시험 생성기와 채점기. `exam/v1/`에는 연 판 v1과 그 열쇠·결과가 있다.
- `answers/v1/`: v1에서 채점한 모든 답 묶음.
- `paper1/`: 이 논문, 한국어 번역본, 그림 스크립트, 검토 기록.

본문의 경로는 이 공개본을 가리킨다. 커밋 해시는 파일을 옮겨 온 비공개 작업 저장소를 가리키며, 같은 파일이 공개본에 있다. Helix Blue의 몸 BatonNet은 짝 저장소 `isolesta-hue/paper-brain-inspired-bionet`에 공개한다. Helix Teal과 Helix Blue의 시험 실행기는 다음 판에 더한다. 아직 열지 않은 판은 공개하지 않는다 — 그 씨앗 말은 여는 날 전에는 존재하지 않는다.

저자와 **AI** 사용 밝힘

저자: isolesta-hue(독립 연구자). 유일한 사람 저자이고 모든 내용에 책임진다 — 연구 물음, 결정, 통과선, 모든 진행·중단. AI 시스템은 저자로 올리지 않고 그 역할을 여기에 밝힌다.

- **개발·실험·글:** Claude(Anthropic), Claude Code로. 학습자마다 보조 세션이 하나씩, 저자의 지시와 연구 규칙 아래 코드를 설계하고 쓰고, 실험을 돌리고, 사전 등록 기록을 두고, 이 논문의 초안을 썼다. 세션마다 자기 저장소를 두었다.
- **아이디어 토론:** ChatGPT(OpenAI)와 Gemini(Google), 무료판. 저자가 연구 아이디어를 두 모델과 토론했고, 각 아이디어는 뒤에 우리 실험 결과로 확인했다.
- **학습 자료:** 학습자가 만난 세상·이야기·시험 문항은 모두 코드(규칙 기반 생성기와 난수 시드)로 만들었다. AI 시스템이 쓴 글은 학습 자료로 쓰지 않았다.

참고문헌

영어 원문의 목록과 같다(27편). 번역하지 않고 원문 그대로 둔다.

- Baillargeon, R. (1987). Object permanence in 3½- and 4½-month-old infants. *Developmental Psychology*, 23(5), 655–664.
- Carey, S., & Bartlett, E. (1978). Acquiring a single new word. *Papers and Reports on Child Language Development*, 15, 17–29.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186.
- Gleitman, L. (1990). The structural sources of verb meanings. *Language Acquisition*, 1(1), 3–55.
- Ha, D., & Schmidhuber, J. (2018). World models. arXiv:1803.10122.
- Howard, M. W., & Kahana, M. J. (2002). A distributed representation of temporal context. *Journal of Mathematical Psychology*, 46(3), 269–299.
- Kruger, J., & Dunning, D. (1999). Unskilled and unaware of it: How difficulties in recognizing one's own incompetence lead to inflated self-assessments. *Journal of Personality and Social Psychology*, 77(6), 1121–1134.
- Lake, B. M., Ullman, T. D., Tenenbaum, J. B., & Gershman, S. J. (2017). Building machines that learn and think like people. *Behavioral and Brain Sciences*, 40, e253.
- Landau, B., Smith, L. B., & Jones, S. S. (1988). The importance of shape in early lexical learning. *Cognitive Development*, 3(3), 299–321.
- Levelt, W. J. M. (1989). *Speaking: From Intention to Articulation*. MIT Press.

- Li, L., Jamieson, K., DeSalvo, G., Rostamizadeh, A., & Talwalkar, A. (2018). Hyperband: A novel bandit-based approach to hyperparameter optimization. *JMLR*, 18(185), 1–52.
- McClelland, J. L., McNaughton, B. L., & O'Reilly, R. C. (1995). Why there are complementary learning systems in the hippocampus and neocortex: Insights from the successes and failures of connectionist models of learning and memory. *Psychological Review*, 102(3), 419–457.
- McCloskey, M., & Cohen, N. J. (1989). Catastrophic interference in connectionist networks: The sequential learning problem. *Psychology of Learning and Motivation*, 24, 109–165.
- Mermillod, M., Bugaiska, A., & Bonin, P. (2013). The stability-plasticity dilemma: Investigating the continuum from catastrophic forgetting to age-limited learning effects. *Frontiers in Psychology*, 4, 504.
- Nelson, T. O., & Narens, L. (1990). Metamemory: A theoretical framework and new findings. *Psychology of Learning and Motivation*, 26, 125–173.
- Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *PNAS*, 115(11), 2600–2606.
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Hambro, E., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. *Advances in Neural Information Processing Systems*, 36.
- Schmidhuber, J. (2003). Gödel machines: Self-referential universal problem solvers making provably optimal self-improvements. arXiv:cs/0309048.
- Siskind, J. M. (1996). A computational study of cross-situational techniques for learning word-to-meaning mappings. *Cognition*, 61(1–2), 39–91.
- Spelke, E. S., & Kinzler, K. D. (2007). Core knowledge. *Developmental Science*, 10(1), 89–96.
- Stevens, J. S., Gleitman, L. R., Trueswell, J. C., & Yang, C. (2017). The pursuit of word meanings. *Cognitive Science*, 41(S4), 638–676.
- Trueswell, J. C., Medina, T. N., Hafri, A., & Gleitman, L. R. (2013). Propose but verify: Fast mapping meets cross-situational word learning. *Cognitive Psychology*, 66(1), 126–156.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Vong, W. K., Wang, W., Orhan, A. E., & Lake, B. M. (2024). Grounded language acquisition through the eyes and ears of a single child. *Science*, 383(6682), 504–511.
- Warstadt, A., Mueller, A., Choshen, L., Wilcox, E., Zhuang, C., Ciro, J., Mosquera, R., Paranjape, B., Williams, A., Linzen, T., & Cotterell, R. (2023). Findings of the BabyLM Challenge: Sample-efficient pretraining on developmentally plausible corpora. *Proceedings of the BabyLM Challenge at the 27th Conference on Computational Natural Language Learning*, 1–34.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *JASA*, 22(158), 209–212.
- Yu, C., & Smith, L. B. (2007). Rapid word learning under uncertainty via cross-situational statistics. *Psychological Science*, 18(5), 414–420.

부록 A. 전체 점수표

`exam/v1/RESULTS.md`(공용 저장소, 커밋 db45a40)를 보라. 답 14벌의 판정 선마다 정답률이 있고, Wilson 아래 끝이 선을 넘으면 ✓ 표시가 있다.

부록 B. 재현

- 판: `python3 -m exam.edition --phrase "아는 것이 힘이다." --lives 30 --out DIR`. manifest의 파일 해시가 모두 `exam/v1/manifest.json`과 같아야 한다(manifest sha256 앞자리 4ac9e0977857).
- 채점: `python3 -m exam.grade --edition exam/v1 --report-only exam_spec/report_only.json --answers NAME=DIR …`.
- Helix Gold 실행기: 시험 코드 지문 0551dd3a140d(v1). torch는 프로세스당 1스레드. 모든 BLAS를 1스레드로 돌리면 답이 끝자리까지 같다(1,097줄에서 확인). 다음 판에는 970dacab9e36(메모리만 바꾼 고침으로 답은 같음; 그다음 읽기가 문항의 대상을 넘김 — 대상이 없는 문항의 답은 그대로, 953줄 중 953줄). 그 뒤 세상 생성기를 바꿔(발견 173~174) 지문은 09a331ed9c14가 되었지만 답은 그대로다(1,097줄 중 1,097줄). 지문은 다음 여는 날 전에 다시 밝힌다.
- Helix Blue 실행기: `python3 -m new_horizons.exam_day --edition DIR --out DIR --shared DIR`(sia-conv-v3, 코드 지문 7d03b3b4d445, 실행기 sha 878e0d99840e; PYTHONHASHSEED=0, BLAS 1스레드 — 4스레드면 답이 일부 바뀜). 30생애를 다시 돌려 판정 답 줄을 모두 재현했다(18,771줄 중 18,771줄; NH 146).
- Helix Teal 실행기: 변환기 지문 1577ace667de, 실행기 131385ea7675; 네 생애를 다시 돌려 줄마다 같음(P56).

부록 C. 기준마다 묻는 관계, 그리고 Helix Gold가 틀리는 곳

`D77_TABLE_V1.md`(Helix Gold 저장소)를 보라. 묶음마다 묻는 관계(상관, 인과, 상호, 선후), 그 사실이 변환된 입력의 한 순간 안에 있는지, 가장 나은 기준선과 Helix Blue에 견준 Helix Gold의 점수, 탐침의 읽기가 있다. Helix Blue의 약한 곳은 모양이 다르다. Helix Gold는 사실이 순간을 넘으면 관계와 상관없이 틀리고, Helix Blue는 자기 읽기로 상호(받침, 맞닿음)와 선후(따라가기)에서 약하다.

부록 D. 기록

발견 69, 100, 111, 115, 120, 122, 123, 125~130, 132, 136, 146, 149, 151, 152, 155, 158~160, 162, 164~174는 Helix Gold 저장소 README에 있고, 각각 사전 등록 실행기와 출력 파일이 있다. §7.7의 자기 세상 기준은 `SCORE_TABLE.md`(Helix Gold 저장소)에 모여 있다. 시험: `exam/`와 `exam/v1/`(공용 저장소). 부품별 탐침: `exam_parts_v1.md`. 진단: `DIAG_JOINED.md`와 `analyse_joined.py`.

부록 E. 형제 세션들의 읽기 (한국어 원문 발췌; 굵은 글씨와 줄바꿈은 뺌)

발췌는 쓰인 그대로 옮겼으므로 프로젝트 안쪽 이름(시아 = Helix Blue, 아라 = Helix Teal)이 남아 있다.

Helix Blue — `STAGE1_REPLY.md` "첫 봉인 판 v1 채점 결과 — 시아가 읽음 (2026-10-21)", 저장소 isolesta-hue/new-transformer-model-research, 브랜치 claude/great-einstein-ln7j5x, 커밋 a078f457, e7cce8c4:

통과한 셋은 각각 덧붙인 부품 하나에 기댐 — C0은 순서 기억 (46, 구조)을 빼면 무너짐 (+0.197 — 조사), C2는 상호 배타성 (47, 구조)을 빼면 (+0.311), C9는 관계 감각의 짝 (49, 회색)을 빼면 (+0.595); 부품을 모두 빼거나 경험 0 (새 몸)이면 통과 0 — 배운 낱말 + 설계한 부품이 함께 풂.

상자 비움 짝은 모든 판 · 경험 0까지 0.593 그대로 — 배움이 아니라 가능도 규칙 (설계)의 버릇임이 확인됨.

Helix Teal — `pioneer/README.md` "P55 — 첫 봉인 판 v1의 결과 읽기", 저장소 isolesta-hue/recursive-improvement-experiment, 브랜치 claude/dazzling-goldberg-sk11yo, 커밋 d500ca89:

아라는 문법(조사 0.99~1.00)과 물리 예측(C6 받침·단단함)은 배웠고, 낱말을 장면 속 대상에 잇는 일(정체·누가·무엇)은 우연 근처, 자리("어디")·수·상태 따라가기는 우연과 같음.

개발 판 점검(가짜 정답 몸 1.000)은 형식만 보고, "이 읽기에서 몸이 그 답의 종류를 낼 수 있나"(길 점검)는 보지 않았다 — 내 설계 실수, 교훈으로 적음.

Helix Teal — `pioneer/README.md` "P56 결과 (E1)", 커밋 80b58629:

P55 ①의 "낱말 ↔ 대상 잇기(정체)가 약함"을 바로잡음 — 잇기는 있다. 다만 들은 문장 틀에 묶여 있어서, 틀이 바뀌면(사람 + "there is", 조사 없는 한국어) 틀의 습관이 장면을 이긴다.

부록 F. 계획 중이거나 보관 중인 연구 (아직 해 보지 않음)

Helix Gold 저장소의 장부(`LEDGER.md`; "장부" 칸이 그 번호)에서 옮겼다. "열림" = 기록해 두고 차례를 기다림, "보관" = 일부러 미룸(까닭을 적음). 여기의 어느 것도 결과가 아니다.

장부	생각	겨냥하는 빈 곳	상태
D81	다음 봉인 판에 답 두 벌: 배움을 재는 뇌와 설계 전체	설계와 배움의 거리를 봉인 조건에서 잼(§7.7)	계획(다음 판)
—	세 학습자가 함께 여는 둘째 봉인 판	각 세션이 자기 세상에서 고친 뒤의 견줌	계획
D4	손대지 않은 새 세상: 같은 능력, 다른 겉모습, 설계·조정에 한 번도 쓰지 않음	아무도 맞추지 않은 일반성	대기(설계 고정)
—	봉인 시험의 답 섞기 대조	전체 판단의 (c), v1에서 돌리지 않음	계획
D76	자기 기준과 물건 기준이 어긋나는 문항(움직이는 관찰자, 남의 시점)	첫 시험에는 두 틀이 있지만 어긋나지 않음	보관 — 학습자 수준이 맞을 때; 때는 소유자가 정함
D20	Helix Gold 자기 세상에서 같은 체급 트랜스포머(같은 자료, 같은 학습 횟수)	설계한 세상 안의 신경망 대조	열림
D63	종류만 맞춘 바깥 눈금: 세상 이해(bAbI 비슷한 과제), 나중에 유창함(TinyStories)	같은 과제라고 주장하지 않고 공개 눈금 위에 놓기	열림
D51	같은 성과에 드는 비용 / 같은 비용에서의 성과	같은 비용에서 학습자 견주기	진행 중(발견마다 기록)
Q14 (가)	문장 틀은 낱말의 종류만, 어느 낱말인지는 장면이 정함	이름 실패(§8)	첫 시도 실패(발견 170); 다음 시도 계획
D80	시험 꼴에서의 순서를 담는 경험: 질문 안의 이야기, 다른 물	시험지 C8	계획(Helix Gold 세상에서 본 움직임·들은 움직임은 끝: 발견 171·172·174)

장부	생각	겨냥하는 빈 곳	상태
	건 기준의 움직임, 문답 없이 질문 뜻 얻기		
D72	새 일반 장치마다 배우는 힘 과목을 다시 잼	장치마다 설계와 배움 가르기	진행 중
D75 2단계	다른 물건 기준의 틀("~ 위에 놓다", "~ 쪽으로 밀다")	시험의 움직임은 대부분 상대적	계획
D77	상관·인과·상호·선후를 가르고 잇는 몸	사실이 순간을 넘으면 Helix Gold는 틀림(부록 C)	열림(첫 표 끝)
D62	연습에서 기호 바꿔 보기 놀이	외우기와 일반 규칙의 다툼(Helix Teal 기록에서처럼)	열림
D44	상호 배타성으로 한 번 듣고 뜻 잡기	한 번 들은 새 낱말(C2 직후 0.26)	열림
D73	공동 주의: 낱말은 말하는 이가 주의하는 것에 붙음	아기가 낱말을 잇는 방식	열림
D74	대화 맥락 따라가기("그거 어디 있어?")	기초 대화로	열림
D61	말로 들은 개수를 상태로 받아들이기	"다음 수"가 우연에 머묾	보관 — 설계 전체에 절차를 더하는 일이라 1단계 뒤
D40, D41, D55	중요한 연결 굳히기, 헷갈린 짝 떼어 놓기, 골라 잊기	생애 후반의 간섭	열림 — 간섭 분석을 기다림
D60	출처 × 상황으로 믿기	들은 증거와 본 증거	열림
D82	모른다는 것을 아는가: 답과 함께 확신을 내고, 확신이 맞는 정도(보정)와 맞은 답·틀린 답을 가르는 정도를 잼	확신 있는 틀림은 배움을 멈추게 함(메타인지의 점검; Nelson & Narens 1990; Kruger & Dunning 1999)	첫 걸음 끝(발견 175): 확신은 몸의 종류 문지기가 기권하는 곳에서만 낮아지고, 부정과 미끄러운 바닥에서는 틀리면서도 높음(정답률 0.20에 0.78, 0.13에 0.80) — 몸은 아직 모른다는 것을 모름. 다음: "설명하지 못한 요소" 신호
D83	부품 = 도구: 부품이 들은 경험에서 실제로 도운 곳을 배워 그 곳에서만 말함(Toolformer의 원리, Schick 외 2023)	설계 전체는 부품이 맞지 않는 곳에서 해침(§7.7; 발견 159)	진행 중
D54	잘못된 전제의 전파 막기	스스로 나아지는 고리는 잘못된 가정을 키울 수 있음	열림
D27	작은 규칙을 조합하는 도서관(결과마다 한 덩어리가 아니라)	옮겨 쓰기와 효율	열림
D52, D53	스스로 최적화하기와 문제 해결을 시험 과목으로	방법 층의 다음 단계	열림
D58, D59	규칙 안의 놀이와 호기심; 생각의 사슬을 끊는 고요 모드	방법 층의 안정	열림
D43	불확실하게 내린 지난 결정을 나중 정보로 되돌아보기	의심 속에서 내린 결정의 질	보관 — 앞선 결과 뒤
D24, D16, D18, D7, D19	그림과 영상; 3차원 세계 좌표와 착시; 공간 + 시간; 더 고운 격자; 원근	5 × 5 글자 그림 세상 너머	뒤 단계

장부	생각	겨냥하는 빈 곳	상태
D26, D30	더 큰 새 버전으로 자라기; 시드 기억과 방 생성기	규모	뒤 단계
D29, D34, D37	학습자 자신의 가치 좌표계, 자신의 공리계, 구조 유추	긴 목표	나중(첫 점수표 뒤)
D33	교재 학습부터의 장기 기억 파일	한 학습자의 연속성	열림(교재 학습과 함께 시작)
D28	수와 기본 사칙연산만으로 쌓는 넷째 학습자	대조 계열	나중(세 학습자 뒤)